

ENGENHARIA DE DADOS · PARTE 1

Lake de resultados eleitorais

Grupo 06

Gabriel Caetano · Henrique Magalhães · João Victor Ferraz · Maria Luisa Coimbra · Maria Luiza Calife · Maria Júlia Menezes

A pergunta e o tamanho dos dados

Como os **votos válidos** para Presidente, Governador e Senador se distribuíram em cada **região do Brasil**, no 1º e no 2º turno de **2018 e 2022**?

36,1 mi

linhas lidas do TSE
(2018 + 2022)

829 mil

linhas dos 3 cargos
da pergunta

50 → 15


colunas: texto
para tipadas

407.921

linhas na trusted,
1 por chave

Fonte: TSE, votação nominal por município e zona · regiões N, NE, CO, SE, S e exterior ·
leitura descritiva


Arquitetura: 100% Terraform, sem Crawler



Terraform · módulo lake · backend **S3 + DynamoDB** · workspace av1 · 3 tags obrigatórias

Limpeza conferida com o TSE


De **36,1 mi** linhas lidas do TSE, 829 mil são dos 3 cargos:



- `_BRASIL.csv` duplica os demais: dedup por fatia **UF** × **cargo**
- Chave provada: **407.921** linhas = **407.921** chaves, **0** repetidas
- Reconciliar com o oficial pegou um erro de **99,8%** na 1ª versão (só o exterior); hoje, diferença **0** nos 4 totais
- **2,26 mi** votos indevidos barrados suplementar 1,69 mi · anulados 0,57 mi

Ganho 1: a camada trusted, no mesmo recorte

MB varridos por consulta



—80%


bytes varridos e custo por consulta

- Por consulta: US\$ **0,00089** na raw, US\$ **0,00018** na trusted
- A cada 1.000 consultas: **US\$ 0,89** contra **US\$ 0,18**

Medido no Athena: consulta 03 (raw) e consulta 02 (trusted) · 1 MB = 2^{20} bytes, como o Athena cobra

Formato: texto puro, um custo aceito


MB cobrados por consulta completa



- gzip: raw **7,7 MB** e trusted **2,8 MB**, abaixo do mínimo de 10 MB cobrado
- Custo aceito: **+28 MB** por consulta na trusted (US\$ 0,00013)
- Em troca, o teto funciona: com gzip, a raw (7,7 MB) ficaria abaixo do menor teto aceito (**10 MB**) e nunca seria barrada
- Sem partição: a pergunta lê **100%** da trusted

Ganhos 2 e 3: medir cada consulta


Consulta 02 reescrita (MB cobrados)



—**50%**

mesmas 12 linhas de resultado


Varredura larga na raw (MB cobrados)



—**40%**

cancelada no teto; a trusted (38 MB) passa

Demonstração: do apply ao destroy



```
$ ./verificacao/verifica.sh
[PASSA] [0] nenhum Crawler: nem no código, nem na conta
[PASSA] [1] módulo lake + backend s3 com lock DynamoDB ...
[PASSA] [2] 3 buckets, database, workgroup e lock: tags ...
[PASSA] [3] trusted com 15 colunas (9 tipadas), grão e chave ...
[PASSA] [4] grão respeitado: 407921 linhas = 407921 chaves ...
[PASSA] [5] votos válidos do 2º turno batem com o TSE ...
[PASSA] [6] pergunta respondida: 149 linhas ...
      cobrado 38 MB · US$ 0.00018120
[PASSA] [7] teto de 111.00 MB: raw morreu (CANCELLED) ...
[PASSA] [8] DECISOES.md: grão, chave, partição, formato e custo
Resultado: 9 PASSA · 0 FALHA
```

```
$ ./verificacao/verifica.sh --pos-destroy
[PASSA] [P1] nenhum bucket eda262-g06-* ...
[PASSA] [P2] database eda262_g06_eleicoes ...
[PASSA] [P3] workgroup eda262-g06-wg ...
[PASSA] [P4] tabela de lock ... não existe
[PASSA] [P5] nenhum recurso com as tags ...
Resultado: 5 PASSA · 0 FALHA
```

Saídas completas em evidencias/verifica_*.txt · linhas abreviadas com ...

A resposta: votos válidos por região

Consulta 01 (pergunta completa): **149 linhas** · **38 MB** cobrados · **US\$ 0,00018**

Presidente, 2º turno: à frente em cada região (% dos votos válidos)				
Região	2018		2022	
N	Bolsonaro (PSL)	51,89	Bolsonaro (PL)	51,03
NE	Haddad (PT)	69,69	Lula (PT)	69,34
CO	Bolsonaro (PSL)	66,55	Bolsonaro (PL)	60,21
SE	Bolsonaro (PSL)	65,37	Bolsonaro (PL)	54,26
S	Bolsonaro (PSL)	68,27	Bolsonaro (PL)	61,84
Exterior	Bolsonaro (PSL)	71,02	Lula (PT)	51,28

2022, 1º turno, partido mais votado por região. **Governador**: N (MDB) · NE (PT) · CO (UNIÃO) · SE (REPUBLICANOS) · S (PSD). **Senador**: PL em 4 das 5 regiões (NE: PT).

Ganhos medidos

—80%

custo e bytes
trusted vs. raw

—50%

consulta 02
reescrita

—40%

prejuízo
com o teto

0

votos de diferença
com o TSE

github.com/JoaovfGoncalves/eda262-projeto-g06 tag av1-entrega

Grupo g06 · Perguntas